

Reliable Numerical Simulation of Financial SDEs

数学推导全过程详解（中文讲义版）

基于同名 PDF 报告整理

2026 年 9 月 22 日

摘要

本文档按原 PDF 的章节顺序，逐步讲解其中的全部数学推导。从布朗增量的量级 *Brownian increment scaling*（布朗增量缩放）与伊藤公式 *Itô's formula*（伊藤公式）出发，推出几何布朗运动 *GBM, geometric Brownian motion*（几何布朗运动）的精确解、期望与方差；再推导欧拉-丸山格式 *Euler-Maruyama, EM*（欧拉-丸山格式）与米尔斯坦格式 *Milstein scheme*（米尔斯坦格式），给出强收敛 *strong convergence*（强收敛）与弱收敛 *weak convergence*（弱收敛）的定义与估计量；随后分析 EM 的一步正性失败概率 *one-step positivity failure probability*（一步正性失败概率）与 Milstein 二次乘子的最小值；然后给出非仿射随机波动率模型 *non-affine stochastic volatility model*（非仿射随机波动率模型）的 EM 格式、相关布朗增量 *correlated Brownian increments*（相关布朗增量）的构造、嵌套网格耦合 *nested-grid coupling*（嵌套网格耦合）、置信区间 *confidence interval*（置信区间），以及对数-对数回归斜率 *log-log regression slope*（对数-对数回归斜率）的数学表达。

阅读约定：关键术语后以括号给出英文原名；标有【为什么这样做】的方框解释推导动机，标有【关键结论】的方框给出必须记住的结果。

目录

1 地基：布朗运动、SDE 与伊藤公式	3
1.1 为什么需要随机微积分	3
1.2 布朗增量的量级：整套理论的起点	3
1.3 SDE 的严格含义：积分方程	3
1.4 伊藤公式：多出来的 $\frac{1}{2}f''$	4
1.5 附带结论： $\int_0^t W_s dW_s = \frac{1}{2}W_t^2 - \frac{1}{2}t$	4
2 GBM 全套：定义、伊藤公式、精确解与矩	4
2.1 SDE 定义（式 (1)）	4
2.2 伊藤公式推 $d\log S_t$ （式 (2)）	5
2.3 精确解（式 (3)）	5
2.4 期望与方差（式 (4)）	5
2.5 基准参数与数值（式 (5)(31)）	6

目录	2
3 离散化：欧拉-丸山与米尔斯坦格式的推导	6
3.1 欧拉-丸山格式 (式 (10))	6
3.2 迭代随机积分 (式 (11))	6
3.3 米尔斯坦格式 (式 (12))	7
3.4 精确转移与路径耦合 (式 (13))	7
4 强收敛、弱收敛与误差估计量	8
4.1 强收敛 (式 (14))	8
4.2 弱收敛 (式 (15))	8
4.3 解析偏差基准 (式 (16))	9
4.4 偏差的一阶渐近 (式 (17)(18))	9
5 正性分析	10
5.1 EM 的一步正性条件与失败概率 (式 (19)(20))	10
5.2 Milstein 的二次乘子与最小值 (式 (21)(22))	10
6 非仿射随机波动率模型	11
6.1 模型定义 (式 (6)(7)(8))	11
6.2 模型正则性与可用理论	11
6.3 相关布朗增量的构造 (式 (23)(24))	12
6.4 非仿射模型的 EM 格式 (式 (25)(26)(27))	12
6.5 为什么不对该模型使用标量 Milstein	12
7 嵌套网格耦合与数值参考解	13
7.1 嵌套网格耦合 (式 (28))	13
7.2 参考解并非精确解 (式 (33))	13
8 置信区间与回归斜率	13
8.1 置信区间 (式 (29))	13
8.2 对数-对数回归斜率及其标准误	14
9 匹配精度下的成本比	14
10 诊断量与结果汇总	15
10.1 增量与参考解诊断 (式 (32)(33))	15
10.2 理论阶与实测阶对照	15
10.3 GBM 耦合收敛数值表	15
10.4 全文推导链条一览	16
A 符号表	16
B 与原 PDF 的对应关系	16
C 一处排版笔误说明	16

1 地基：布朗运动、SDE 与伊藤公式

1.1 为什么需要随机微积分

普通微积分处理 $dx = f'(t)dt$ 这类式子，路径是光滑的。股价路径不是光滑的：它处处连续但处处不可微，因此 dS_t/dt 不存在。我们只能写

$$dS_t = \underbrace{\mu S_t dt}_{\text{确定趋势}} + \underbrace{\sigma S_t dW_t}_{\text{随机扰动}}, \quad (1)$$

其中 dW_t 是布朗运动的增量 *Brownian increment* (。首要问题是： dW_t 的量级 *order of magnitude* (是多大?)

1.2 布朗增量的量级：整套理论的起点

【为什么这样做】 后面所有推导（伊藤公式、迭代随机积分、鞅性质、耦合降方差）都依赖下面这个量级分析。它是整个随机微积分与数值方法的基石。

设 W 为标准布朗运动 *standard Brownian motion* (，则 $\Delta W = W_{t+h} - W_t \sim N(0, h)$ ，于是

$$\mathbb{E}[(\Delta W)^2] = h, \quad \text{Var}((\Delta W)^2) = 2h^2. \quad (2)$$

第一式的意思是 $(\Delta W)^2$ 的平均值恰好是 h ；第二式说明它围绕 h 的涨落是 $O(h)$ 阶，因此

$$\mathbb{E}[(\Delta W)^2 - h]^2 = 2h^2 \rightarrow 0. \quad (3)$$

这就是非形式地写 $(dW_t)^2 = dt$ 的严格来源：它不是约定，而是被「平方的均值收敛到 h 、方差是 h^2 阶」这件事逼出来的。由此得到伊藤乘法表 *Itô multiplication table* (

$$(dW_t)^2 = dt, \quad dt \cdot dW_t = 0, \quad (dt)^2 = 0. \quad (4)$$

【为什么这样做】 为什么 $dt dW_t = 0$? 因为 $|\Delta t \Delta W| \leq h \cdot O(\sqrt{h}) = O(h^{3/2})$, 求和后为 $O(\sqrt{h}) \rightarrow 0$, 比 $O(h)$ 更高阶，故可丢弃。

【关键结论】 $(dW)^2 = dt$ 是全部的来源。只要记住这一条，伊藤公式中多出的 $\frac{1}{2}f''$ 就不神秘了。

1.3 SDE 的严格含义：积分方程

$dS_t = \mu S_t dt + \sigma S_t dW_t$ 本身没有独立含义，它只是积分方程 *integral equation* (的缩写：

$$S_t = S_0 + \int_0^t \mu S_u du + \int_0^t \sigma S_u dW_u. \quad (5)$$

右端第二项是**伊藤积分** *Itô integral* (，定义为非预期（左端点）黎曼和的均方极限 *mean-square limit* (：

$$\int_0^T H_u dW_u = \lim_{\|\Pi\| \rightarrow 0} \sum_k H_{t_k} (W_{t_{k+1}} - W_{t_k}). \quad (6)$$

【为什么这样做】必须取左端点 H_{t_k} ，即被积函数与增量不重叠（非预期性 *non-anticipativity*）。若改用中点，得到的是斯特拉托诺维奇积分 *Stratonovich integral*（链式法则回到普通微积分形式，但会失去鞅性质）。

伊藤积分满足两条基本性质：

$$\mathbb{E}\left[\int_0^T H_u dW_u\right] = 0, \quad \mathbb{E}\left[\left(\int_0^T H_u dW_u\right)^2\right] = \mathbb{E}\int_0^T H_u^2 du \quad (\text{伊藤等距 Itô isometry}). \quad (7)$$

这两条是后面计算 $\mathbb{E}[S_T]$ 、 $\mathbb{E}[S_T^2]$ ，以及解释「耦合为何能降低方差」的全部基础。

1.4 伊藤公式：多出来的 $\frac{1}{2}f''$

【为什么这样做】这是全文最核心的一步。普通泰勒展开中 $(\Delta x)^2 = O(h^2)$ 是高阶小量；但在随机世界里 Δx 含 $O(\sqrt{h})$ 的布朗部分，于是 $(\Delta x)^2$ 中含 $O(h)$ 项，与一阶项同阶，不能丢弃。

设 $dX_t = a dt + b dW_t$ 。把 $(dX_t)^2$ 展开并用乘法表式 (4)：

$$(dX_t)^2 = (a dt + b dW_t)^2 = \underbrace{b^2 dt}_{\text{保留}} + \underbrace{2ab dt dW_t}_{=0} + \underbrace{a^2 (dt)^2}_{=0} = b^2 dt. \quad (8)$$

而 $(dX)^3$ 含 $(dW)^3$ ，量级为 $h^{3/2}$ ，求和后 $O(\sqrt{h}) \rightarrow 0$ ，可丢。于是得到伊藤公式 *Itô's formula* (：

$$df(t, X_t) = \left(f_t + af_x + \frac{1}{2}b^2 f_{xx}\right)dt + bf_x dW_t. \quad (9)$$

1.5 附带结论： $\int_0^t W_s dW_s = \frac{1}{2}W_t^2 - \frac{1}{2}t$

【为什么这样做】§3 推导 Milstein 时要用迭代随机积分 *iterated stochastic integral*（其最简版本就是这一条。先在这里把它算清楚）。

取 $f(x) = \frac{1}{2}x^2$ （故 $f' = x$ ， $f'' = 1$ ）代入式 (9)：

$$d\left(\frac{1}{2}W_t^2\right) = W_t dW_t + \frac{1}{2}dt \implies \int_0^t W_s dW_s = \frac{1}{2}W_t^2 - \frac{1}{2}t. \quad (10)$$

与普通微积分 $\int x dx = \frac{1}{2}x^2$ 相比多出的 $-\frac{1}{2}t$ ，完全来自 $\frac{1}{2}f''$ 项。写成增量形式即

$$\int_{t_n}^{t_{n+1}} \int_{t_n}^s dW_r dW_s = \frac{1}{2}[(\Delta W_n)^2 - h]. \quad (11)$$

2 GBM 全套：定义、伊藤公式、精确解与矩

2.1 SDE 定义 (式 (1))

在物理测度 *physical measure*（下，几何布朗运动 *GBM*（为

$$dS_t = \mu S_t dt + \sigma S_t dW_t, \quad S_0 > 0, \quad (12)$$

其中 μ 为漂移率 *drift rate*（ $\sigma > 0$ 为波动率 *volatility*）。

【为什么这样做】「几何」的含义是：系数 μS_t 、 σS_t 与当前价格成正比，于是价格按「比例」（收益率 *return*（）演化。这正对应金融经验事实——收益率与价格水平无关。代价是真解恒为正 ($S_t > 0$)，这为后面的正性分析埋下伏笔。

2.2 伊藤公式推 $d \log S_t$ (式 (2))

【为什么这样做】 dS_t 中 S_t 以乘性出现，方程不好处理；取对数把它变成加性方程，漂移与扩散都成为常数，立即可积。这是解 GBM 的标准思路。

取 $f(s) = \log s$ ，则

$$f'(s) = \frac{1}{s}, \quad f''(s) = -\frac{1}{s^2}. \quad (13)$$

代入式 (9) (此处 $a = \mu S_t$, $b = \sigma S_t$)，先算两项：

$$f'(S_t) dS_t = \frac{1}{S_t} (\mu S_t dt + \sigma S_t dW_t) = \mu dt + \sigma dW_t, \quad (14)$$

$$\frac{1}{2} f''(S_t) (dS_t)^2 = -\frac{1}{2S_t^2} \cdot \sigma^2 S_t^2 dt = -\frac{1}{2} \sigma^2 dt. \quad (15)$$

式 (15) 中用了式 (8) 的 $(dS_t)^2 = \sigma^2 S_t^2 dt$ 。两式相加得到

$$d \log S_t = \left(\mu - \frac{1}{2} \sigma^2 \right) dt + \sigma dW_t. \quad (16)$$

【关键结论】 真实的对数收益率不是 μdt ，而是 $(\mu - \frac{1}{2} \sigma^2) dt$ 。多出的 $-\frac{1}{2} \sigma^2$ 称为**波动拖累** *volatility drag* (与式 (10) 中的 $-\frac{1}{2} t$ 同源。它说明 σ 越大，几何平均增长越慢，即使算术平均 μ 不变。

2.3 精确解 (式 (3))

【为什么这样做】 式 (16) 右端系数全为常数，因此对时间的积分就是普通黎曼积分，不需要再处理伊藤项。这就是「取对数」的好处。

从 0 积到 t ：

$$\log S_t - \log S_0 = \left(\mu - \frac{1}{2} \sigma^2 \right) t + \sigma W_t. \quad (17)$$

两边取指数 (e^x 是确定性光滑函数，不再产生新的伊藤项)：

$$S_t = S_0 \exp \left[\left(\mu - \frac{1}{2} \sigma^2 \right) t + \sigma W_t \right]. \quad (18)$$

因为 $W_t \sim N(0, t)$ ，所以

$$\log S_t \sim N \left(\log S_0 + \left(\mu - \frac{1}{2} \sigma^2 \right) t, \sigma^2 t \right), \quad (19)$$

即 S_t 服从**对数正态分布** *lognormal distribution* (。

2.4 期望与方差 (式 (4))

【为什么这样做】 这是全文唯一的闭式基准 (oracle)。有了它，数值格式的弱误差 (均值偏差) 可以精确算出，无需用参考解近似。

回忆对数正态矩公式 *lognormal moment formula* (：若 $X \sim N(m, s^2)$ ，则 $\mathbb{E}[e^X] = e^{m + \frac{1}{2} s^2}$ 。于是

$$\mathbb{E}[S_T] = S_0 e^{(\mu - \frac{1}{2} \sigma^2) T} \cdot e^{\frac{1}{2} \sigma^2 T} = S_0 e^{\mu T}. \quad (20)$$

注意 $\frac{1}{2} \sigma^2$ 恰好抵消——这不是巧合，它说明 μ 就是期望收益率。

同理 $S_T^2 = S_0^2 e^{(2\mu - \sigma^2)T} e^{2\sigma W_T}$ ，再用一次矩公式 ($m = (2\mu - \sigma^2)T$, $s = 2\sigma\sqrt{T}$):

$$\mathbb{E}[S_T^2] = S_0^2 e^{(2\mu - \sigma^2)T} \cdot e^{\frac{1}{2}(2\sigma)^2 T} = S_0^2 e^{2\mu T} e^{\sigma^2 T}, \quad (21)$$

故

$$\text{Var}(S_T) = \mathbb{E}[S_T^2] - (\mathbb{E}[S_T])^2 = S_0^2 e^{2\mu T} (e^{\sigma^2 T} - 1). \quad (22)$$

2.5 基准参数与数值 (式 (5)(31))

$$S_0 = 100, \quad \mu = 0.05, \quad \sigma = 0.40, \quad T = 1. \quad (23)$$

代入得

$$\mathbb{E}[S_T] = 100e^{0.05} = 105.127110, \quad \text{Var}(S_T) = 100^2 e^{0.1} (e^{0.16} - 1) = 1917.591686. \quad (24)$$

【为什么这样做】 方差很大 (标准差 ≈ 43.8 , 相对波动 $\approx 41.7\%$)。当 $M = 3 \times 10^5$ 条路径时, 均值的蒙特卡洛标准误约为 $43.8/\sqrt{3 \times 10^5} \approx 0.080$ 。这说明**抽样噪声 *sampling noise* (与离散偏差 *discretisation bias* (必须分开处理——这正是原报告反复强调「耦合」的原因)。**

3 离散化：欧拉-丸山与米尔斯坦格式的推导

3.1 欧拉-丸山格式 (式 (10))

【为什么这样做】 SDE 的积分形式里两个积分都算不出来 (需要知道整条路径)。最朴素的办法是：在一个步长内把系数「冻结」在左端点。这与伊藤积分本身取左端点天然一致。

对单步 $[t_n, t_{n+1}]$ 写积分形式, 并把被积的 S_u 近似为 $S_{t_n} \equiv S_n$ (常数), 于是两个积分都变得平凡:

$$\int_{t_n}^{t_{n+1}} \mu S_n du = \mu S_n h, \quad \int_{t_n}^{t_{n+1}} \sigma S_n dW_u = \sigma S_n \Delta W_n. \quad (25)$$

得到**欧拉-丸山格式 *Euler-Maruyama scheme*** (:

$$S_{n+1}^{\text{EM}} = S_n^{\text{EM}} + \mu S_n^{\text{EM}} h + \sigma S_n^{\text{EM}} \Delta W_n = S_n^{\text{EM}} (1 + \mu h + \sigma \Delta W_n), \quad \Delta W_n = \sqrt{h} Z_n. \quad (26)$$

其中 $Z_n \sim N(0, 1)$ 独立, 这是 $\Delta W_n \sim N(0, h)$ 的可实现形式。

【关键结论】 这里留下两笔「欠账」: 一是冻结系数带来的误差; 二是——更关键地——对扩散系数 σS_u 的冻结比对漂移 μS_u 的冻结严重得多。后者正是 Milstein 的动机。

3.2 迭代随机积分 (式 (11))

【为什么这样做】 Milstein 的全部内容, 就是把 EM 丢掉的下一项伊藤-泰勒 *Itô-Taylor* (项加回来; 而那一项就是这个二重随机积分。它必须被显式算出, 才能得到可实现的格式。

在 $[t_n, s]$ 上用式 (10) 得 $\int_{t_n}^s dW_r = W_s - W_{t_n}$; 再对 s 从 t_n 积分到 t_{n+1} :

$$\int_{t_n}^{t_{n+1}} \int_{t_n}^s dW_r dW_s = \int_{t_n}^{t_{n+1}} (W_s - W_{t_n}) dW_s. \quad (27)$$

对 $f(x) = \frac{1}{2}x^2$ 作用于 $W_s - W_{t_n}$ (漂移为 0、扩散为 1):

$$d\left[\frac{1}{2}(W_s - W_{t_n})^2\right] = (W_s - W_{t_n})dW_s + \frac{1}{2}ds. \quad (28)$$

两端从 t_n 积到 t_{n+1} , 得

$$\int_{t_n}^{t_{n+1}} \int_{t_n}^s dW_r dW_s = \frac{1}{2}(W_{t_{n+1}} - W_{t_n})^2 - \frac{1}{2}h = \frac{1}{2}[(\Delta W_n)^2 - h]. \quad (29)$$

【关键结论】 一个漂亮的检验: $\Delta W_n = \sqrt{h}Z$ 且 $\mathbb{E}[Z^2] = 1$, 故

$$\mathbb{E}\left[\frac{1}{2}(hZ^2 - h)\right] = 0, \quad \text{Var}\left[\frac{1}{2}(hZ^2 - h)\right] = \frac{h^2}{4}\text{Var}(Z^2) = \frac{h^2}{2} = O(h^2). \quad (30)$$

即该积分项均值 0、标准差 $h/\sqrt{2}$ ——典型大小是 $O(h)$ 阶, 与漂移项同阶。所以 EM 丢掉它不是丢高阶小量, 而是丢了一个真正的 $O(h)$ 项, 这直接解释了 EM 强阶为何只有 1/2。

3.3 米尔斯坦格式 (式 (12))

【为什么这样做】 EM 把扩散系数 $b(s) = \sigma s$ 冻结成 $b(S_n)$, 但 b 在一步内其实在变化。把 b 也在 S_n 处作一阶展开, 并保留伊藤-泰勒的二重积分项, 即可消掉领先的 $O(h)$ 误差。

按 $b(S_u) \approx b(S_n) + b'(S_n)(S_u - S_n)$ 展开, 并注意一步内 $S_u - S_n \approx b(S_n)(W_u - W_{t_n})$ (漂移贡献为更高阶):

$$\int_{t_n}^{t_{n+1}} b(S_u) dW_u \approx b(S_n) \Delta W_n + b(S_n)b'(S_n) \int_{t_n}^{t_{n+1}} \int_{t_n}^s dW_r dW_s. \quad (31)$$

对 GBM, $b(s) = \sigma s$, 故 $b'(s) = \sigma$, $b(S_n)b'(S_n) = \sigma^2 S_n$ 。代入式 (29) 得到 **米尔斯坦格式 Milstein scheme** (:

$$S_{n+1}^{\text{Mil}} = S_n^{\text{Mil}} + \mu S_n^{\text{Mil}} h + \sigma S_n^{\text{Mil}} \Delta W_n + \frac{1}{2} \sigma^2 S_n^{\text{Mil}} [(\Delta W_n)^2 - h]. \quad (32)$$

【关键结论】 把它写成乘子形式, 并与精确解的一步乘子比较:

$$S_{n+1}^{\text{Mil}} = S_n^{\text{Mil}} \left[1 + \mu h + \sigma \Delta W_n + \frac{1}{2} \sigma^2 ((\Delta W_n)^2 - h) \right], \quad (33)$$

$$e^{(\mu - \frac{1}{2}\sigma^2)h + \sigma \Delta W_n} = 1 + \sigma \Delta W_n + (\mu - \frac{1}{2}\sigma^2)h + \frac{1}{2}\sigma^2 (\Delta W_n)^2 + O(h^{3/2}). \quad (34)$$

二者到 $O(h)$ 完全一致: Milstein 乘子正是精确乘子的二阶泰勒截断。这解释了它为何能把标量强阶由 1/2 提升到 1, 而弱阶仍为 1。

3.4 精确转移与路径耦合 (式 (13))

【为什么这样做】 要测量「离散误差」, 必须让三个解面对完全相同的随机性, 否则量到的是抽样噪声。

对同一个 ΔW_n , 由式 (18) 在 $[t_n, t_{n+1}]$ 上取比例, 得**精确转移 exact transition** (:

$$S_{n+1}^{\text{exact}} = S_n^{\text{exact}} \exp\left[(\mu - \frac{1}{2}\sigma^2)h + \sigma \Delta W_n\right]. \quad (35)$$

于是精确解、EM、Milstein 三条路径共用同一个增量序列 $\{\Delta W_n\}$ 。这种做法称为**路径耦合** *pathwise coupling* (也常称为共用随机数 *common random numbers*)。

【为什么这样做】 定量理由：若精确路径与数值路径相互独立，则差值方差包含两条路径各自的方差（约为 $2\text{Var}(S_T)$ ），蒙特卡洛标准误为 $O(M^{-1/2})$ 。当 $M = 3 \times 10^5$ 时该标准误约为 0.11，而 $h = 1/256$ 处真实误差仅约 0.59——同一量级，斜率会被噪声完全淹没。耦合后差值方差大幅缩小，收敛阶才可辨。

4 强收敛、弱收敛与误差估计量

4.1 强收敛 (式 (14))

定义 4.1 (强收敛 *strong convergence*)。若对任意足够细的步长 h 有

$$\left(\mathbb{E}|S_N^{(h)} - S_T|^2\right)^{1/2} \leq Ch^p, \quad h \rightarrow 0, \quad (36)$$

则称该格式的**强收敛阶** *strong order of convergence* (为 p)。

强收敛是**逐路径精度** *pathwise accuracy* (关心单条路径的准确性，适用于对冲 *hedging* (路径依赖期权 *path-dependent option* (与耦合构造。其估计量 (终端强误差) 为

$$\hat{e}_s(h) = \frac{1}{M} \sum_{m=1}^M |S_{N,m}^{(h)} - S_{T,m}^{\text{exact}}|. \quad (37)$$

【为什么这样做】 为什么用平均绝对误差 (MAE, *mean absolute error*) 而不是均方根误差？两者满足相同的收敛阶，但绝对值对少数极端路径不敏感，蒙特卡洛方差更小，拟合出的斜率更稳定。

【为什么这样做】 斜率怎么估？取若干步长 h_j ，令 $y_j = \log \hat{e}_s(h_j)$ 、 $x_j = \log h_j$ 。若 $\hat{e}_s(h) \approx Ch^p$ ，则 $y_j \approx \log C + p x_j$ 是一条直线，用最小二乘拟合斜率即得 p (详见 §8)。

4.2 弱收敛 (式 (15))

定义 4.2 (弱收敛 *weak convergence*)。若对属于某类光滑检验函数 *test function* (的 ϕ 有

$$|\mathbb{E} \phi(S_N^{(h)}) - \mathbb{E} \phi(S_T)| \leq Ch^q, \quad (38)$$

则称该格式的**弱收敛阶** *weak order of convergence* (为 q)。

弱收敛是**分布级精度** *law-level accuracy* (关心期望 (价格) 而非路径，用于欧式期权定价 *European option pricing* (。弱误差记为

$$e_w(h) = |\mathbb{E} \phi(S_N^{(h)}) - \mathbb{E} \phi(S_T)|. \quad (39)$$

4.3 解析偏差基准 (式 (16))

【为什么这样做】 弱误差需要 $\mathbb{E}\phi(S_T)$ ，一般要蒙特卡洛，噪声很大。但对线性检验函数 $\phi(s) = s$ ，GBM 给出闭式答案，可以完全无噪声地测出弱阶。

记两个格式的一步乘子 (multiplier) 为

$$M_{\text{EM}} = 1 + \mu h + \sigma \Delta W_n, \quad M_{\text{Mil}} = 1 + \mu h + \sigma \Delta W_n + \frac{1}{2} \sigma^2 [(\Delta W_n)^2 - h]. \quad (40)$$

关键观察： 两个乘子的条件期望都等于 $1 + \mu h$ 。这里 $\mathcal{F}_n$ 表示到时刻 t_n 的 σ -代数 filtration ((已有信息))：

$$\mathbb{E}[M_{\text{EM}} | \mathcal{F}_n] = 1 + \mu h + \underbrace{\sigma \mathbb{E}[\Delta W_n]}_{=0} = 1 + \mu h, \quad (41)$$

$$\mathbb{E}[M_{\text{Mil}} | \mathcal{F}_n] = 1 + \mu h + \frac{1}{2} \sigma^2 \left(\underbrace{\mathbb{E}[(\Delta W_n)^2]}_{=h} - h \right) = 1 + \mu h. \quad (42)$$

式 (42) 用了 $\mathbb{E}[(\Delta W_n)^2] = \text{Var}(\Delta W_n) + (\mathbb{E}\Delta W_n)^2 = h$ ，即式 (2)。

于是用**迭代期望** (塔性质 *tower property*) 逐步回推：

$$\mathbb{E}[S_{n+1}] = \mathbb{E}[\mathbb{E}[S_n M_n | \mathcal{F}_n]] = \mathbb{E}[S_n] \cdot (1 + \mu h). \quad (43)$$

递推 N 次 (从 S_0 出发) 得

$$\mathbb{E}[S_N^{\text{EM}}] = \mathbb{E}[S_N^{\text{Mil}}] = S_0(1 + \mu h)^N. \quad (44)$$

【关键结论】 两个含义：(i) EM 与 Milstein 的期望价格**完全相同**，故式 (44) 对两者通用——这正是原报告表 2 中「exact weak-bias 列由两者共用」的原因；(ii) 该式对任意 N 精确成立 (不是渐近近似)，因此是一个零噪声的基准 oracle。

4.4 偏差的一阶渐近 (式 (17)(18))

【为什么这样做】 $(1 + \mu h)^N$ 是精确值却看不出「阶」。把它展开成 h 的幂，就能读出主项与阶，从而预测回归斜率应当等于 1。

用 $N = T/h$ 与标准的泰勒展开 $\log(1 + \mu h) = \mu h - \frac{1}{2} \mu^2 h^2 + O(h^3)$ ：

$$\begin{aligned} (1 + \mu h)^{T/h} &= \exp\left[\frac{T}{h} \log(1 + \mu h)\right] = \exp\left[\frac{T}{h} \left(\mu h - \frac{1}{2} \mu^2 h^2 + O(h^3)\right)\right] \\ &= \exp\left[\mu T - \frac{1}{2} \mu^2 T h + O(h^2)\right] = S_0^{-1} S_0 e^{\mu T} \left[1 - \frac{1}{2} \mu^2 T h + O(h^2)\right], \end{aligned} \quad (45)$$

其中最后一步用了 $e^x = 1 + x + O(x^2)$ 。与精确期望 $S_0 e^{\mu T}$ 相减并取绝对值：

$$e_w(h) = |S_0(1 + \mu h)^{T/h} - S_0 e^{\mu T}| = \frac{1}{2} S_0 e^{\mu T} \mu^2 T h + O(h^2). \quad (46)$$

【关键结论】 主项与 h 成正比，故弱阶 $q = 1$ ，对 EM 与 Milstein 都成立 (因为式 (44) 相同)。

例 4.3 (数值感受). 渐近系数为 $\frac{1}{2} \times 105.127 \times 0.05^2 \times 1 = 0.13141$ ，即 $e_w(h) \approx 0.13141 h$ 。原报告在 $h = 0.25$ 处报告偏差 0.032576，即 $0.1303 h$ ，与渐近系数已很接近；拟合斜率为 0.9982，与 $q = 1$ 精确吻合。

5 正性分析

5.1 EM 的一步正性条件与失败概率 (式 (19)(20))

【为什么这样做】 真解 $S_t > 0$ 恒成立 (因为式 (18) 是指数形式), 但 EM 是线性更新, 乘子可能为负, 导致价格变负、失去金融意义。我们需要把这个结构性缺陷量化为一个概率。

EM 一步为 $S_{n+1} = S_n(1 + \mu h + \sigma \Delta W_n)$ 。写 $\Delta W_n = \sqrt{h} Z_n$, $Z_n \sim N(0, 1)$ 。只要 $S_n > 0$, S_{n+1} 的符号就完全由乘子决定:

$$1 + \mu h + \sigma \sqrt{h} Z_n > 0 \iff Z_n > -\frac{1 + \mu h}{\sigma \sqrt{h}}. \quad (47)$$

失败 (即 $S_{n+1} \leq 0$) 当且仅当上式反向, 于是一步失败概率 *one-step failure probability* (为

$$p_{\text{neg,EM}}(h) = \mathbb{P}\left(Z < -\frac{1 + \mu h}{\sigma \sqrt{h}}\right) = \Phi\left(-\frac{1 + \mu h}{\sigma \sqrt{h}}\right) > 0. \quad (48)$$

其中 Φ 是标准正态分布函数 *standard normal CDF* (。

【关键结论】 该概率恒为正 (高斯尾部再小也不为零), 故 EM 在价格空间 **永远不保正** *not positivity preserving* (。这是格式的结构性缺陷, 不是参数选择问题。

例 5.1 (与观测对照: 用式 (23) 的参数). • $h = 1$: 阈值为 $-1.05/0.4 = -2.625$, $\Phi(-2.625) = 0.00433$, 即 0.433%。此时 $N = 1$, 单步即全程, 与观测 0.435% 相符。

• $h = 1/2$: 阈值为 $-1.025/(0.4 \times 0.7071) = -3.624$, $\Phi(-3.624) = 1.45 \times 10^{-4}$; 全程 $N = 2$ 步约为 2.9×10^{-4} , 即 0.029%, 与观测 0.034% 相符。

• $h \leq 1/4$: 阈值 ≤ -5.13 , $\Phi \approx 1.4 \times 10^{-7}$, $N = 4$ 步约为 5.8×10^{-7} ; 乘以 3×10^5 条路径, 期望出现不到一条, 故观测为零。

因此「细网格观测为 0」的含义是样本中未抽到, 而不是数学保证。尾部衰减极快: 阈值每增大 1, Φ 缩小约一个半数量级。

5.2 Milstein 的二次乘子与最小值 (式 (21)(22))

【为什么这样做】 Milstein 的乘子是 Z 的二次函数, 而二次函数有下界; 下界是否大于零, 就决定了它能否保正。

把 $\Delta W_n = \sqrt{h} Z_n$ 代入 Milstein 乘子:

$$q(z) = 1 + \mu h + \sigma \sqrt{h} z + \frac{1}{2} \sigma^2 (hz^2 - h) = \frac{1}{2} \sigma^2 h z^2 + \sigma \sqrt{h} z + 1 + \mu h - \frac{1}{2} \sigma^2 h. \quad (49)$$

配方 (把一次项吸收进完全平方):

$$\begin{aligned} q(z) &= \frac{1}{2} \sigma^2 h \left(z + \frac{1}{\sigma \sqrt{h}} \right)^2 - \frac{1}{2} + 1 + \mu h - \frac{1}{2} \sigma^2 h \\ &= \underbrace{\frac{1}{2} + \mu h - \frac{1}{2} \sigma^2 h}_{=: q_{\min}} + \frac{1}{2} \sigma^2 h \left(z + \frac{1}{\sigma \sqrt{h}} \right)^2 \geq q_{\min}, \end{aligned} \quad (50)$$

因为最后一项 ≥ 0 , 最小值在 $z^* = -1/(\sigma \sqrt{h})$ 处取得:

$$q_{\min} = \frac{1}{2} + \mu h - \frac{1}{2} \sigma^2 h. \quad (51)$$

例 5.2 (本参数下为何 Milstein 从不违反正性). $\mu = 0.05$, $\sigma = 0.40$, 故 $\frac{1}{2}\sigma^2 h = 0.08h$, 于是

$$q_{\min}(h) = \frac{1}{2} + 0.05h - 0.08h = \frac{1}{2} - 0.03h \geq 0.47 > 0 \quad (0 < h \leq 1). \quad (52)$$

这解释了原报告为何在 Milstein 下从未观测到正性违反。但 $q_{\min}$ 依赖 μ, σ, h : 若 σ 很大或 μ 负得较多, $q_{\min}$ 可以变负——因此 Milstein **不是无条件保证** *unconditional positivity preservation* (。

6 非仿射随机波动率模型

6.1 模型定义 (式 (6)(7)(8))

记 $X_t = \log S_t$ 。所给模型为

$$dX_t = \left(\mu - \frac{1}{2}g(Y_t)^2 \right) dt + g(Y_t) dW_t^{(1)}, \quad (53)$$

$$dY_t = \kappa(\theta - Y_t) dt + \xi \sqrt{1 + Y_t^2} dW_t^{(2)}, \quad (54)$$

$$g(y) = \sigma_{\min} + \frac{\sigma_{\max} - \sigma_{\min}}{1 + e^{-y}}, \quad d\langle W^{(1)}, W^{(2)} \rangle_t = \rho dt. \quad (55)$$

其中 κ 为均值回复速度 *mean-reversion speed* (, θ 为长期均值 *long-run mean* (, ξ 为波动率的波动率 *vol-of-vol* (, ρ 为相关系数 *correlation* ((此处 $\rho = -0.7$ 体现杠杆效应 *leverage effect* (股价下跌 $\Rightarrow$ 波动率上升)。基准参数为

$$\begin{aligned} S_0 = 100, \quad Y_0 = 0, \quad \mu = 0.05, \quad \kappa = 2, \quad \theta = -0.2, \quad \xi = 0.6, \\ \rho = -0.7, \quad \sigma_{\min} = 0.10, \quad \sigma_{\max} = 0.50, \quad T = 1. \end{aligned} \quad (56)$$

【为什么这样做】 为什么叫「非仿射」*non-affine* (? 因为波动率 $g(Y_t)$ 对 Y 不是线性函数, 也不是 S 的常数倍 (对比 Heston 模型的仿射结构)。因此该模型**没有闭式解**, 只能数值求解——这正是「没有精确转移时怎么办」这一研究问题的由来。

6.2 模型正则性与可用理论

【为什么这样做】 标准 EM 收敛定理要求系数满足全局 Lipschitz 条件 *global Lipschitz condition* (与线性增长条件 *linear growth condition* (。必须逐条核对本模型是否满足, 否则「EM 强阶 1/2」的说法就没有依据。

- g 的值域为 $(\sigma_{\min}, \sigma_{\max}) = (0.10, 0.50)$, 故 g **有界** *bounded* (且 $g'(y) = (\sigma_{\max} - \sigma_{\min}) \frac{e^{-y}}{(1 + e^{-y})^2}$ 亦有界。
- $\frac{d}{dy} \sqrt{1 + y^2} = \frac{y}{\sqrt{1 + y^2}}$, 其绝对值 ≤ 1 , 故 $y \mapsto \sqrt{1 + y^2}$ 是全局 Lipschitz 且线性增长的 (注意: $\sqrt{1 + y^2}$ 本身不是线性函数, 但由 $|y|/\sqrt{1 + y^2} \leq 1$ 可推出 $|\sqrt{1 + y_1^2} - \sqrt{1 + y_2^2}| \leq |y_1 - y_2|$)。
- 漂移 $\kappa(\theta - y)$ 显然全局 Lipschitz。

因此「全局 Lipschitz 且线性增长 $\Rightarrow$ EM 强阶 1/2、弱阶 1」的标准结论适用, 为后面的实测强阶 0.5111 提供了理论预期。但需注意: 下方使用的有限参考解 *numerical reference* (仍然是数值基准, 并非闭式 oracle。

6.3 相关布朗增量的构造 (式 (23)(24))

【为什么这样做】 模型含两个相关系数为 ρ 的布朗运动。要用两个独立标准正态随机数作线性变换 (Cholesky 分解 *Cholesky factorisation*) 来**精确**实现该相关结构, 而不是近似。

取 $Z_{1,n}, Z_{2,n} \stackrel{iid}{\sim} N(0, 1)$, 令

$$\Delta W_n^{(1)} = \sqrt{h} Z_{1,n}, \quad \Delta W_n^{(2)} = \sqrt{h} (\rho Z_{1,n} + \sqrt{1 - \rho^2} Z_{2,n}). \quad (57)$$

验证 (利用 $Z_1 \perp Z_2$):

$$\text{Var}(\Delta W_n^{(1)}) = h, \quad \text{Var}(\Delta W_n^{(2)}) = h(\rho^2 + (1 - \rho^2)) = h, \quad (58)$$

$$\text{Cov}(\Delta W_n^{(1)}, \Delta W_n^{(2)}) = h \mathbb{E}[Z_1(\rho Z_1 + \sqrt{1 - \rho^2} Z_2)] = h(\rho \cdot 1 + \sqrt{1 - \rho^2} \cdot 0) = \rho h, \quad (59)$$

于是相关系数 *correlation coefficient* (恰为

$$\text{Corr} = \frac{\rho h}{\sqrt{h} \cdot \sqrt{h}} = \rho. \quad (60)$$

【关键结论】 $\sqrt{1 - \rho^2}$ 的作用是保证 $\Delta W^{(2)}$ 的方差恰好为 h 。若漏掉它, 它就不是标准布朗增量, 模型被改变。这也解释了自动检验为何同时检查方差 (1, 1) 与相关系数 -0.7 : 它们分别锁定式 (58) 与式 (60)。

6.4 非仿射模型的 EM 格式 (式 (25)(26)(27))

【为什么这样做】 推导逻辑与 §3 完全相同: 把每个系数冻结在左端点。唯一的细节是漂移里的 g 也必须用 Y_n (左端点已知值), 因为 $g(Y_u)$ 在步内是未知的。

$$X_{n+1} = X_n + \left(\mu - \frac{1}{2} g(Y_n)^2 \right) h + g(Y_n) \Delta W_n^{(1)}, \quad (61)$$

$$Y_{n+1} = Y_n + \kappa(\theta - Y_n)h + \xi \sqrt{1 + Y_n^2} \Delta W_n^{(2)}, \quad (62)$$

$$S_{n+1} = e^{X_{n+1}} > 0. \quad (63)$$

【关键结论】 式 (63) 的保正是**结构性的** *structural* (: 指数函数的值域为 $(0, \infty)$), 无论 X_n 多么极端 (甚至 $X_n \rightarrow -\infty$), 都有 $e^{X_n} > 0$ 。它不是从有限样本推断出的经验性质, 而是由变量替换 $X = \log S$ 保证的。原报告图 5 的措辞「enforced by the model representation rather than inferred from a finite sample」正指此点。

6.5 为什么不对该模型使用标量 Milstein

【为什么这样做】 按两个独立布朗驱动写出扩散向量场后: g 依赖 Y , $\sqrt{1 + Y^2}$ 依赖 Y , 而 X 的扩散也依赖 Y , 因此**交叉导数非零**。标量 Milstein 公式只处理 $\partial b / \partial x \cdot b$ 这一项; 多维 Milstein 还需要交叉项 $\partial b^i / \partial x^j b^j$ 以及模拟迭代随机积分 (含 Lévy 面积 *Lévy area*)。略去这些却声称强阶 1, 在数学上是不成立的。

这是一个很好的严谨性示范: 原报告明确**拒绝**在不实现这些交叉项的情况下宣称非仿射模型具有强阶 1。

7 嵌套网格耦合与数值参考解

7.1 嵌套网格耦合 (式 (28))

【为什么这样做】粗网格解要与「参考解」比较，但参考解本身也是数值的。若两者使用独立随机数，比较结果会混入抽样噪声。解决办法：先生成细网格增量，粗增量由细增量求和得到。

设细步长 $h_{\text{ref}} = T/N_{\text{ref}}$ ，粗步长 $h = Kh_{\text{ref}}$ (即粗一步等于细 K 步)。对每个粗步 n ，取细步 $Kn, \dots, Kn + K - 1$:

$$\Delta W_{n,\text{coarse}}^{(i)} = \sum_{j=0}^{K-1} \Delta W_{Kn+j,\text{ref}}^{(i)}, \quad i = 1, 2. \quad (64)$$

【关键结论】为什么正确：布朗运动具有独立增量，且

$$W_{t_{n+1}} - W_{t_n} = \sum_{j=0}^{K-1} (W_{t_n+(j+1)h_{\text{ref}}} - W_{t_n+jh_{\text{ref}}}), \quad (65)$$

即增量的可加性 *additivity of increments* (。分布上，

$$\sum_{j=0}^{K-1} \Delta W_{Kn+j,\text{ref}}^{(i)} \sim N(0, Kh_{\text{ref}}) = N(0, h), \quad (66)$$

与直接生成 $\sqrt{h}Z$ 同分布。但耦合版本更强：它们是同一个 ω (同一样本点) 上的同一条布朗路径。因此粗解与参考解之差反映的是纯离散误差，而非抽样噪声。

这正是原报告算法 1 的结构：先生成细网格增量 $\rightarrow$ 在参考网格上积分 $\rightarrow$ 对每个 N 按式 (64) 聚合增量 $\rightarrow$ 在粗网格上积分 $\rightarrow$ 存成对的终端差 *paired differences* (。

7.2 参考解并非精确解 (式 (33))

【为什么这样做】必须检验「参考解够不够细」，否则误差趋势可能被参考解的自身偏差污染。

原报告取 $N_{\text{ref}} = 2048$ ，并在 4000 条新的耦合路径上与 4096 步比较，得终端价的平均绝对变化

$$|\overline{\Delta S_T}| = 0.057626, \quad 95\% \text{ 置信区间 } [0.056114, 0.059139]. \quad (67)$$

该量远小于最粗网格的强误差 0.886，故参考解足以支撑所观测到的趋势；但它约为 $N = 256$ 处误差 (0.210677) 的 27%，因此不能据此报告更多终端位数或分辨弱偏差。

【关键结论】「数值参考解 $\neq$ 精确 oracle」是本节的核心信息。原报告因此只用它论证强收敛趋势，而不声称弱阶。

8 置信区间与回归斜率

8.1 置信区间 (式 (29))

【为什么这样做】任何蒙特卡洛均值都带抽样误差，必须给出区间，否则无法判断「差异是否真实」。这是原报告反复强调「不制造弱阶结论」的技术手段。

设路径级观测 *path-level observation* ($D_1, \dots, D_M$ 独立同分布 (例如 $D_m = S_{N,m}^{(h)} - S_{T,m}^{\text{exact}}$, 或成对的看涨期权收益差 *paired call-payoff difference*)。令

$$\bar{D} = \frac{1}{M} \sum_{m=1}^M D_m, \quad s_D^2 = \frac{1}{M-1} \sum_{m=1}^M (D_m - \bar{D})^2, \quad (68)$$

则 95% 置信区间 *confidence interval* (为

$$\bar{D} \pm 1.96 \frac{s_D}{\sqrt{M}}. \quad (69)$$

【为什么这样做】 为什么是 1.96? 由中心极限定理 *central limit theorem* ($\bar{D}$ 近似正态、标准差为 $s_D/\sqrt{M}$; 标准正态的 97.5% 分位数 $\Phi^{-1}(0.975) = 1.95996$, 对应双侧 95%。为什么除以 $\sqrt{M}$? 独立同分布均值的方差为 $\text{Var}(D)/M$, 故标准差为 $s_D/\sqrt{M}$ ——这就是蒙特卡洛误差 $O(M^{-1/2})$ 的来源。为什么分母用 $M-1$? 用 $\bar{D}$ 代替未知真均值损失一个自由度, 除以 $M-1$ 才使 $\mathbb{E}[s_D^2] = \text{Var}(D)$ 无偏 (贝塞尔修正 *Bessel's correction*)。

注 8.1. 原报告表 4 的看涨期权收益偏差的 95% 置信区间**全部包含** 0 (例如 $N = 32$ 时为 $[-0.006056, 0.014005]$)。正确的结论是「抽样不确定度已与弱偏差相当, 数据不支持报告弱阶」, 而不是「弱偏差为零」。这是统计推断纪律的示范。

8.2 对数-对数回归斜率及其标准误

【为什么这样做】 理论上误差为 Ch^p , 但 C 与 p 都未知, 我们只有有限网格上的误差观测。取对数把幂律变成直线, 于是可以用标准最小二乘 *ordinary least squares* (估出 p 。

取 J 个网格 $h_1, \dots, h_J$, 令 $y_j = \log \hat{e}_s(h_j)$ 、 $x_j = \log h_j$ 。若 $\hat{e}_s(h) \approx Ch^p$, 则

$$y_j = \log C + p x_j + \varepsilon_j, \quad (70)$$

最小二乘估计为

$$\hat{p} = \frac{\sum_{j=1}^J (x_j - \bar{x})(y_j - \bar{y})}{\sum_{j=1}^J (x_j - \bar{x})^2}, \quad \hat{a} = \bar{y} - \hat{p} \bar{x} \quad (\text{即 } \log \hat{C}), \quad (71)$$

斜率的标准误 *standard error of the slope* (为

$$\text{se}(\hat{p}) = \sqrt{\frac{\hat{\sigma}^2}{\sum_{j=1}^J (x_j - \bar{x})^2}}, \quad \hat{\sigma}^2 = \frac{1}{J-2} \sum_{j=1}^J (y_j - \hat{a} - \hat{p} x_j)^2. \quad (72)$$

注 8.2. $\text{se}(\hat{p})$ 只刻画**给定网格范围内直线拟合本身**的不确定性, 它**不是**重复蒙特卡洛实验的不确定度, 也不包含网格范围选择等模型不确定性。因此「EM 斜率 0.4899 ± 0.0026 」中的 $\pm$ 是回归诊断 *regression diagnostic* (, 而不是蒙特卡洛置信区间。这一点原报告特别声明过。

9 匹配精度下的成本比

【为什么这样做】 绝对误差不能直接比较方法优劣——必须在**同一精度目标**下比成本, 否则「Milstein 更准」并不能推出「Milstein 更划算」。

预先声明目标 $\mathbb{E}|S_N - S_T| \leq 0.85$ 。查 GBM 收敛表:

- EM: $N = 64$ 时 $1.18565 > 0.85$ 不达标; $N = 128$ 时 $0.838329 \leq 0.85$ 达标, 故 $N_{\text{EM}} = 128$ 。
- Milstein: $N = 2$ (即 $h = 0.5$) 时 $0.75433 \leq 0.85$ 达标, 故 $N_{\text{Mil}} = 2$ 。

在「每步一次系数求值」的步数成本度量 *declared cost measure* (下:

$$\frac{C_{\text{EM}}}{C_{\text{Mil}}} = \frac{128}{2} = 64. \quad (73)$$

注 9.1 (重要限定). 这是**算法步数比**, 不是墙钟加速比 *wall-clock speedup* (。理由: (i) Milstein 每步多算一个修正项 $(\Delta W_n)^2 - h$, 浮点运算更多; (ii) 未计入随机数生成、内存分配、编译与 I/O 开销。此外该比较还隐含一个「负面结论」: 在极宽松的精度要求下, EM 更廉价的代数可能反而有利, 而本目标区间并未覆盖该区域。

10 诊断量与结果汇总

10.1 增量与参考解诊断 (式 (32)(33))

【为什么这样做】 嵌套耦合与相关增量的正确性必须被**独立检验**, 否则强收敛结果可能源于错误的随机数缩放或错误的相关系数。

增量诊断 (检验式 (60)):

$$\frac{\widehat{\text{Var}}(\Delta W^{(1)})}{h} = 1.00526, \quad \frac{\widehat{\text{Var}}(\Delta W^{(2)})}{h} = 1.00346, \quad \widehat{\text{Corr}} = -0.70185, \quad (74)$$

对照目标 (1, 1, -0.7)。另外 20000 条参考路径全部有限且为正。

【为什么这样做】 为什么方差估计要除以 h ? 因为标准布朗增量满足 $\text{Var}(\Delta W) = h$, 所以「方差估计 $\div h$ 」应接近 1。这样定义的检验量无量纲、与步长无关, 从而成为一个干净的检验。

10.2 理论阶与实测阶对照

表 1: 理论收敛阶与实测阶对照

对象	理论阶	实测阶	结论
EM 强阶	1/2	0.4899 ± 0.0026	一致
Milstein 强阶	1	0.9099 ± 0.0167	接近 1 (前渐近效应)
均值弱偏差阶	1	0.9982 ± 0.0004	一致
非仿射 EM 强阶	1/2	0.5111 ± 0.0047	一致
非仿射弱阶	1	未报告	置信区间含 0, 数据不足

10.3 GBM 耦合收敛数值表

快速核对: EM 的 MAE 在 h 减半时大致乘以 $1/\sqrt{2} \approx 0.707$ ($4.52887 \rightarrow 3.28870$, 比值 0.726); Milstein 大致乘以 $1/2$ ($0.460308 \rightarrow 0.268833$, 比值 0.584); 偏差列精确减半 ($0.0325759 \rightarrow 0.0163567$, 比值 0.502)。

表 2: GBM 耦合收敛 ($M = 300,000$ 条路径)

N	h	EM 强误差 MAE	Milstein 强误差 MAE	精确均值偏差
4	0.250000	4.52887	0.460308	0.0325759
8	0.125000	3.28870	0.268833	0.0163567
16	0.062500	2.34715	0.149881	0.00819567
32	0.031250	1.67424	0.0800666	0.00410218
64	0.015625	1.18565	0.0414826	0.00205218
128	0.0078125	0.838329	0.0211342	0.00102636
256	0.00390625	0.594648	0.0106906	0.000513248

10.4 全文推导链条一览

表 3: 推导链条与「为什么」的对应关系

结果	为什么必须这样做
$(dW)^2 = dt$	平方的期望是 h 、方差是 h^2 阶, 故 dW^2 与 dt 同阶, 不能丢
伊藤公式 $\frac{1}{2}f''$	随机情形下 $(\Delta x)^2$ 含 $O(h)$ 项, 与一阶项同阶
取对数解 GBM	把乘性方程变成常系数加性方程, 立即可积
EM 冻结系数	伊藤积分取左端点, 与格式天然一致
Milstein 加迭代积分	EM 丢掉的是 $O(h)$ 项 (标准差 $h/\sqrt{2}$), 必须补回
路径耦合	差值方差从 $\approx 2 \text{Var}(S_T)$ 降到很小, 否则 $O(M^{-1/2})$ 噪声淹没 $O(h^p)$ 信号
$(1 + \mu h)^N$	两格式乘子条件期望相同, 故一阶矩精确可算, 弱阶无噪声可测
$p_{\text{neg,EM}} = \Phi(\cdot)$	乘子为高斯, 负值即线性更新保正失败
q_{min} 配方	二次函数有下界, 下界符号决定是否保正
$X = \log S$ 积分	指数值域为 $(0, \infty)$, 结构性保正
嵌套网格求和	布朗增量可加, 粗细网格共享同一路径
$\bar{D} \pm 1.96 s_D / \sqrt{M}$	CLT + 双侧 95% + 无偏方差修正
log-log 回归	幂律变直线, 最小二乘估斜率 p

A 符号表

B 与原 PDF 的对应关系

C 一处排版笔误说明

原 PDF 式 (31) 处印为 `qqquad` (缺少反斜杠), 正确写法应为 `\qqquad`。本文档式 (24) 已按正确写法给出。

符号	含义	英文术语
W_t	标准布朗运动	standard Brownian motion
ΔW_n	一个步长的布朗增量, $\sim N(0, h)$	Brownian increment
S_t, S_n	资产价格 (连续 / 离散)	asset price
μ	漂移率	drift rate
σ	波动率	volatility
$h = T/N$	时间步长	time step
Z_n	标准正态随机数	standard normal variate
Φ	标准正态分布函数	standard normal CDF
$\mathcal{F}_n$	到 t_n 的信息 (σ -代数)	filtration
ρ	两个布朗运动的相关系数	correlation coefficient
$g(\cdot)$	logistic 波动率函数	logistic volatility map
N_{ref}	参考解 (细网格) 步数	reference step count
$\hat{e}_s(h)$	强误差估计量 (终端 MAE)	strong error estimator
$e_w(h)$	弱误差	weak error
$p_{\text{neg,EM}}$	EM 一步失败概率	one-step failure probability
q_{min}	Milstein 二次乘子最小值	minimum of quadratic multiplier

原 PDF 位置	本文档位置
§2.1 式 (1)–(4)	§2
§2.2 式 (6)–(8)	§6
§3.1 式 (10)	§3
§3.2 式 (11)–(12)	§3
§3.3 式 (13)–(14)	§3 , §4
§3.4 式 (15)–(18)	§4
§3.5 式 (19)–(22)	§5
§3.6 式 (23)–(27)	§6
§3.7 式 (28)	§7
§3.8 式 (29)	§8
§§5.2 式 (30)	§9
§5.6 式 (32)–(33)	§10